

Estrategia de Procesamiento de Señales EEG en Sistemas BCI utilizando Aprendizaje Profundo y Medidas de Conectividad

Yessica Alejandra Gomez Rivera
yeagomezri@unal.edu.co



Universidad Nacional de Colombia
Control y Procesamiento Digital de Señales - GCPDS
Advisor: Andrés Marino Álvarez Meza, Ph.D.
Co-advisor: César Germán Castellanos Domínguez, Ph.D.

7 de octubre de 2024



Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

4 Metodología

5 Conclusiones

6 Referencias



Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

4 Metodología

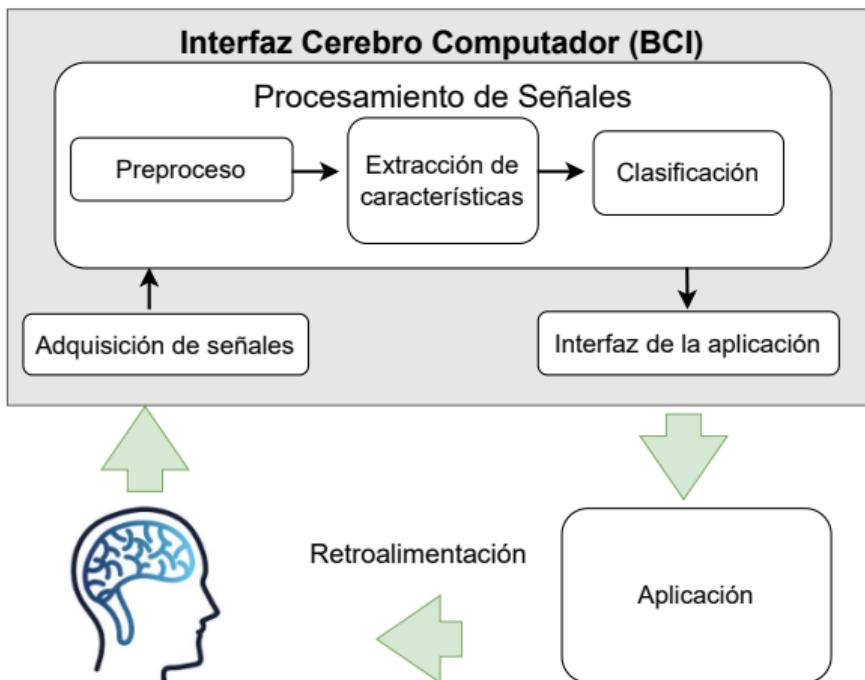
5 Conclusiones

6 Referencias



Motivación

Las Interfaces Cerebro Computador (BCI), establecen una conexión directa entre el cerebro humano y una computadora [Padfield et al., 2019].



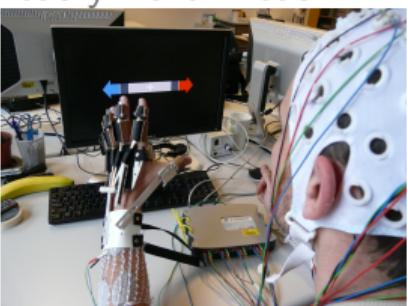


Aplicaciones de Sistemas BCI

El uso de señales neurofisiológicas para desarrollar sistemas BCI se debe a su amplio potencial de aplicaciones clínicas y no clínicas:

Clínicas

- Protocolos médicos [Choi et al., 2020]
- Diagnóstico [Fraiwan et al., 2021]
- Neurorrehabilitación [Padfield et al., 2019]
- Rehabilitación funcional [Miao et al., 2020]



No clínicas

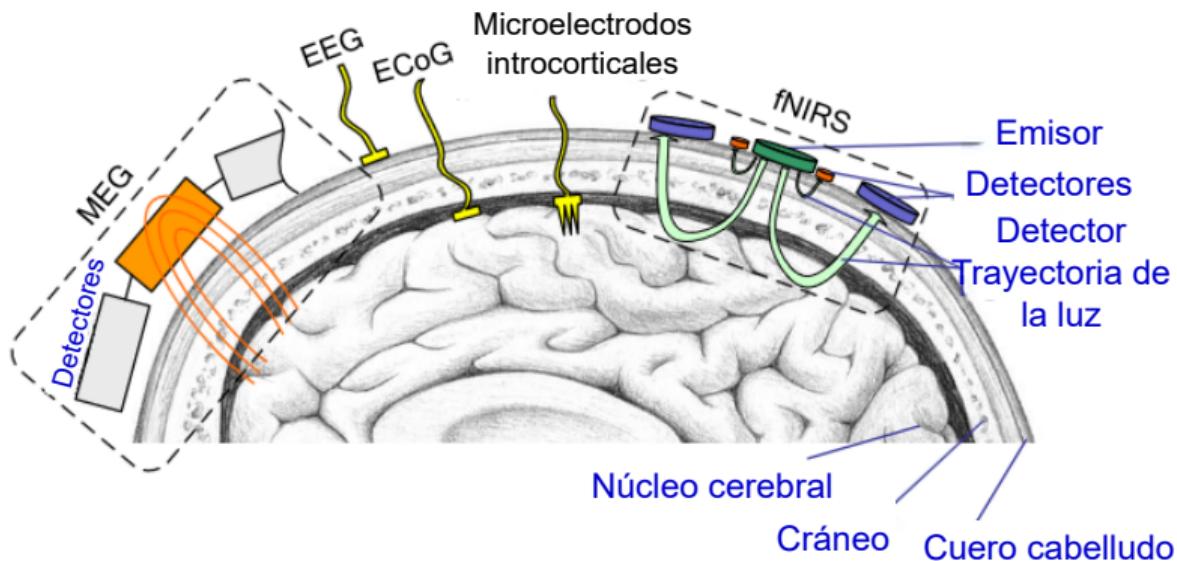
- Neuromarketing [Tremmel et al., 2019]
- Control de videojuegos [Padfield et al., 2019]
- Educación [Taherian and Davies, 2018]





Tipos de Montaje de Sensores BCI

Invasivos (IM), semi-invasivos (ECoG) y no invasivos (MEG, EEG, fNIRS) [Peksa and Mamchur, 2023].

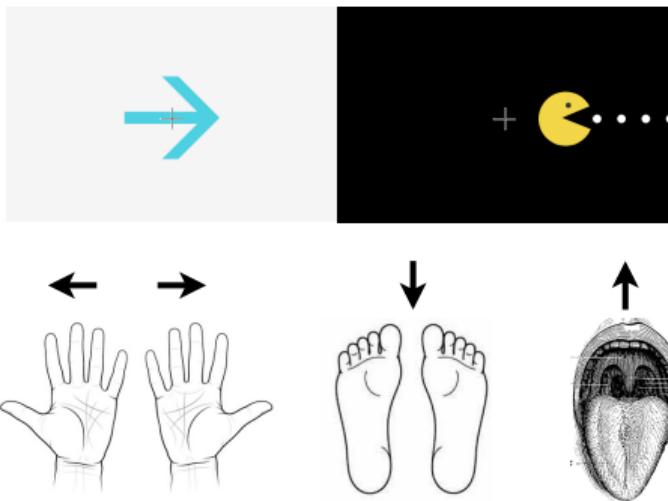


EEG: no invasiva, alta resolución temporal, bajo costo y portabilidad [Miao et al., 2020].



Imaginación Motora (MI)

La actividad cognitiva de imaginar un movimiento, pero no realizarlo [Zapparoli et al., 2020].

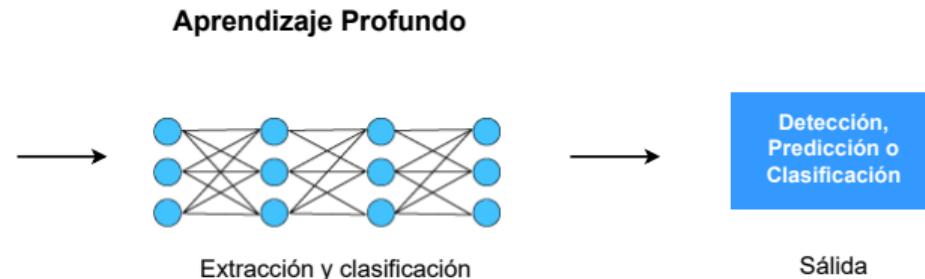
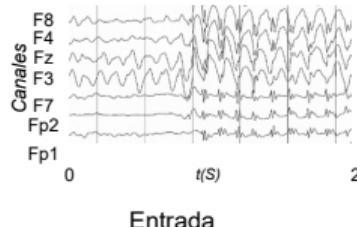
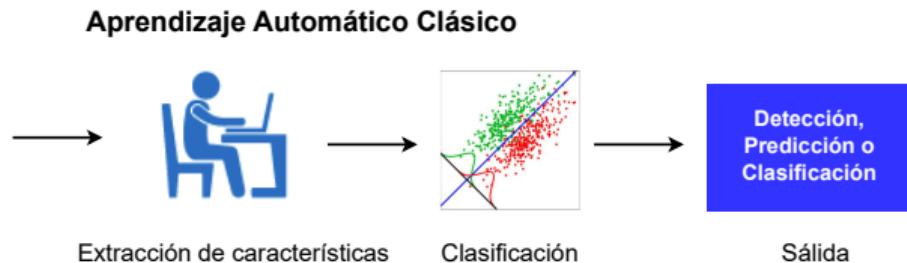
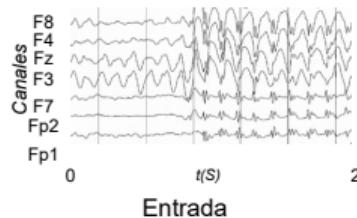


La imaginación motora abarca dos tipos: interna (imaginarse uno mismo realizando la tarea) y externa (imaginar a otra persona realizándola).



Aprendizaje Automático Clásico vs Aprendizaje Profundo

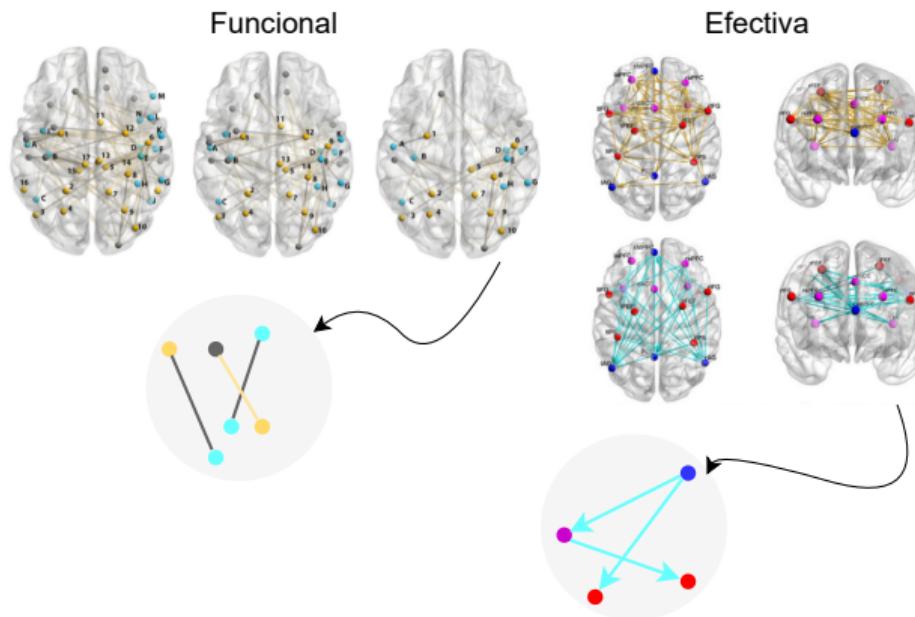
Detección de Enfermedades Neurológicas [Mir et al., 2023] y Clasificación de MI [Chintamani et al., 2021].





Medidas de Conectividad

Conectividad Funcional captura la similitud entre diferentes canales de EEG [Hsu, 2014].

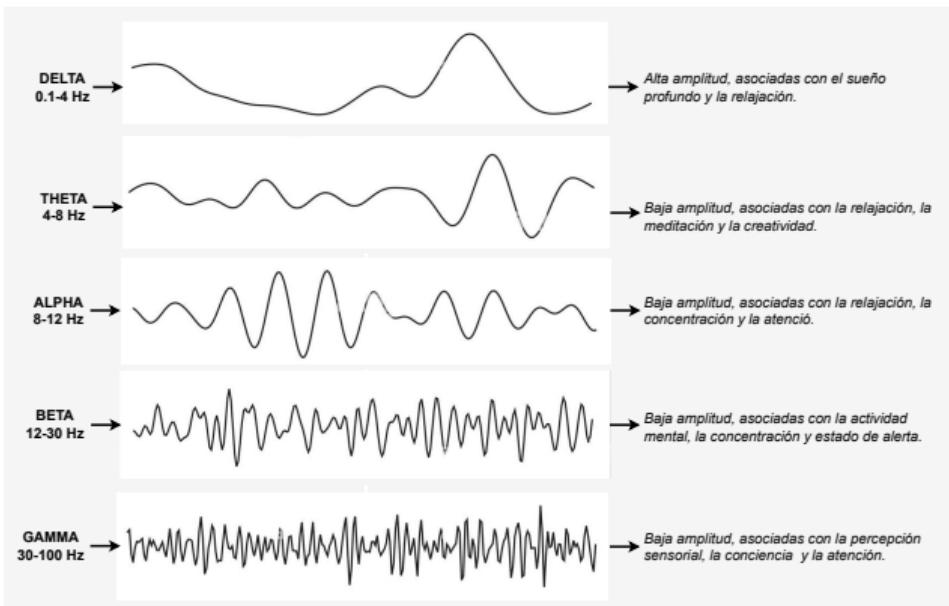


Efectiva se refiere a las interacciones causales dirigidas [Farahani et al., 2019].



Ritmos Cerebrales

Extraemos información relevante sobre los ritmos cerebrales asociados con la tarea de MI [García-Murillo et al., 2023].



$$\mu \text{ (8-12 Hz)}, \beta_I \text{ (12-15 Hz)}, \beta_m \text{ (15-20 Hz)} \text{ y } \beta_h \text{ (18-40 Hz)}.$$



Grupo de Control y Procesamiento Digital de Señales (GCPDS)

El GCPDS trabaja en el desarrollo de software y hardware para la adquisición de datos neurofisiológicos [Cardona-Álvarez et al., 2023].



UNIVERSIDAD
NACIONAL
DE COLOMBIA

S.E.S Hospital
Universitario
de Caldas
Queremos devolver sonrisas



En la actualidad, el GCPDS está desarrollando procedimientos de seguimiento de neonatos en unidades de cuidado intensivo neonatal.



Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

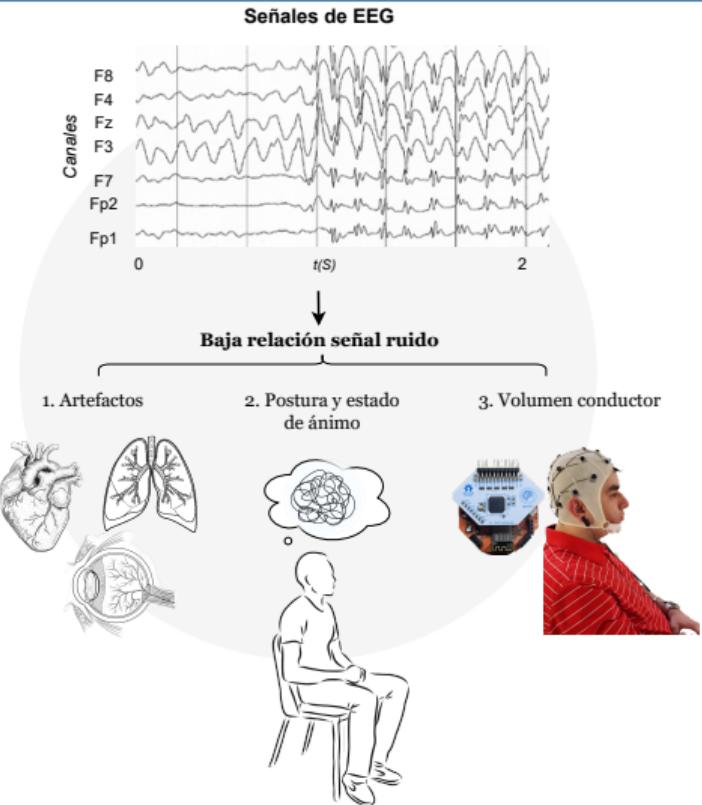
4 Metodología

5 Conclusiones

6 Referencias



Problema #1: Variabilidad Intersujeto

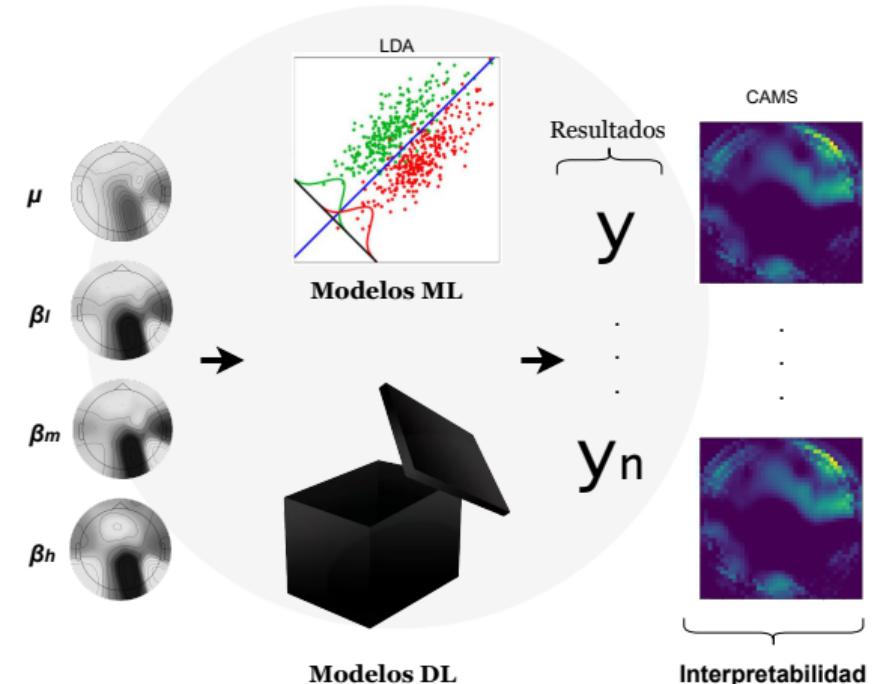


- Las señales de EEG enfrenta restricciones inherentes, como la no estacionariedad, no linealidad y baja resolución espacial [Bozhokin and Suslova, 2021].
- Las señales pueden verse afectadas por artefactos, además los usuarios no logran obtener un control suficiente sobre el BCI [Wriessnegger et al., 2020].
- La cantidad de canales necesarios en la tarea de MI varía entre sujetos, lo que puede influir en la restricción del volumen conductor. [Xygonakis et al., 2018].



Problema #2: Interpretabilidad espacio-frecuencia

- Las limitaciones en la resolución espacial de los electrodos EEG, la claridad en la distribución espacial y el contenido de frecuencia pueden ser insuficientes [Bozhokin and Suslova, 2021].
- Los sesgos presentes en los conjuntos de datos o modelos pueden llevar a decisiones injustas en el uso de algoritmos de ML [Meng et al., 2022].





Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

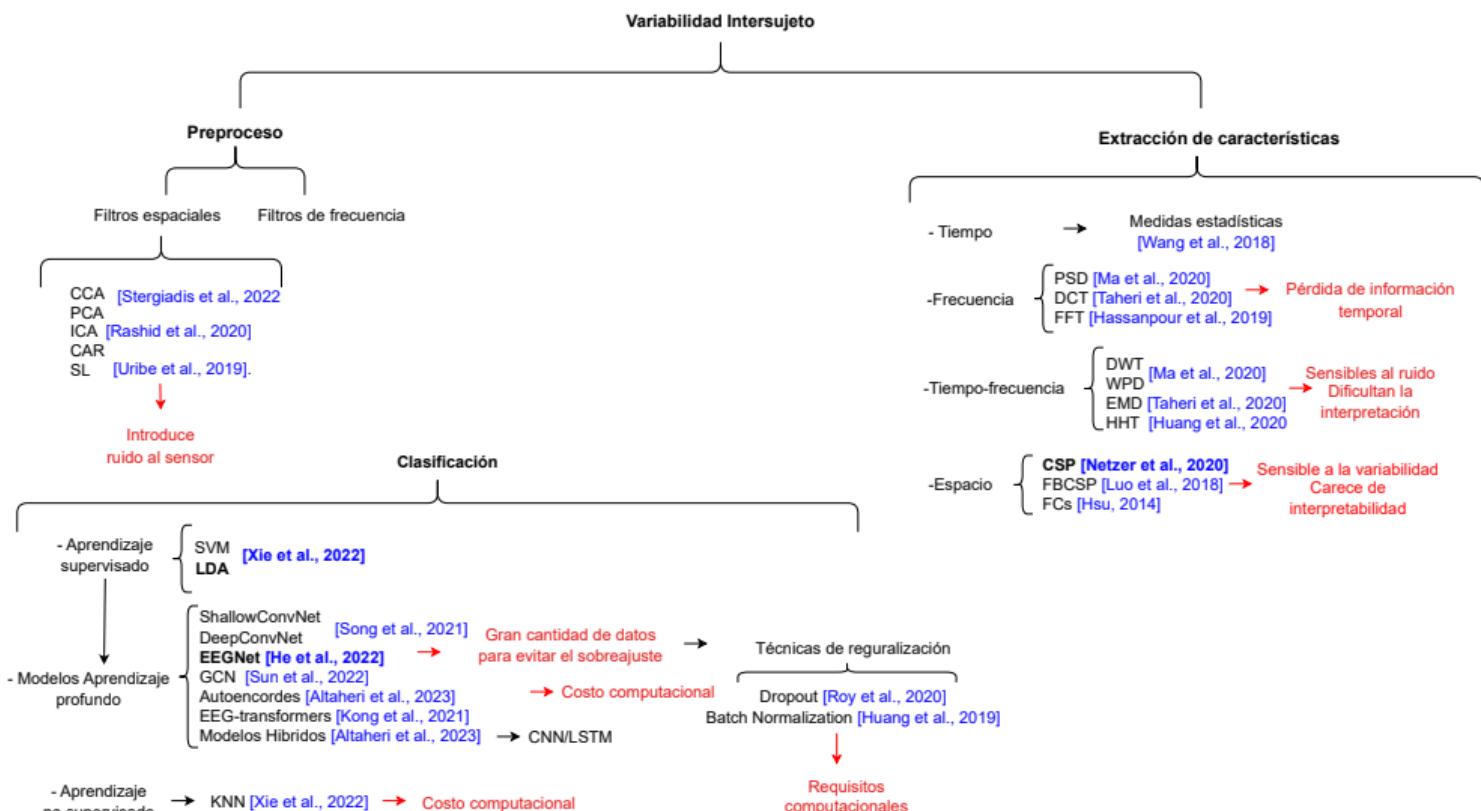
4 Metodología

5 Conclusiones

6 Referencias

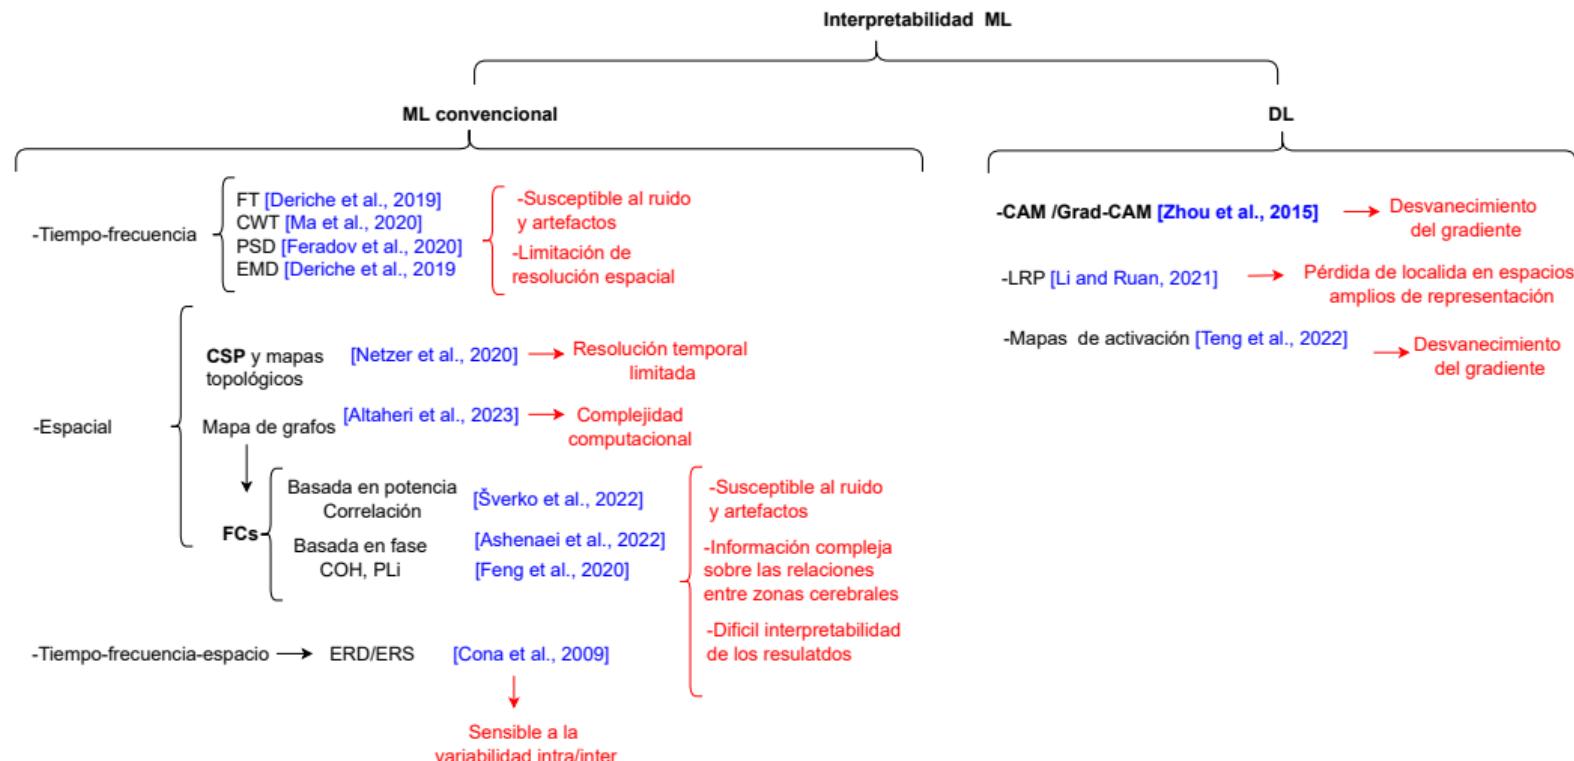


Abordaje de la Variabilidad Intersujeto en BCI-MI basados en EEG





Enfoques de Interpretabilidad en BCI-MI basadas en EEG





Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

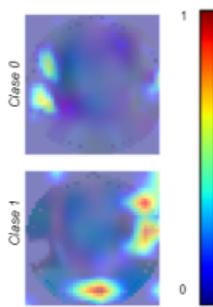
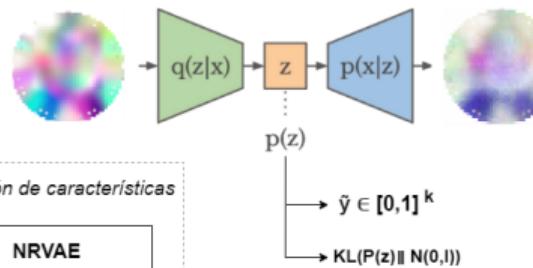
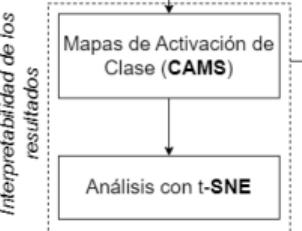
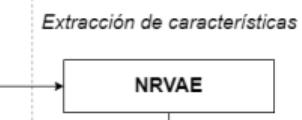
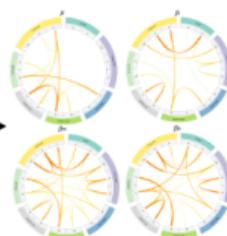
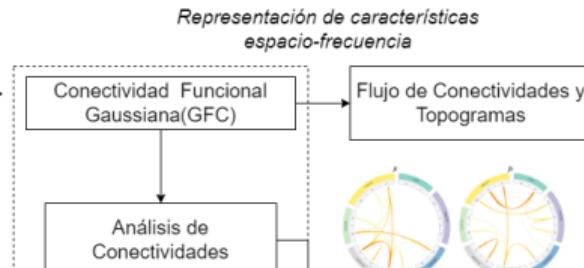
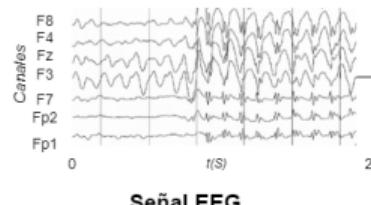
4 Metodología

5 Conclusiones

6 Referencias



Metodología



Métodos de comparación: EEGnet.



Filtrado Laplaciano de Superficie

Una señal de EEG $\mathbf{X}_n \in \mathbb{R}^{C \times T}$, C es el número de canales, T es el número de muestras. $\mathbf{X}_L \in \mathbb{R}^{C \times T}$, se calcula como se muestra en [Carvalhaes and De Barros, 2015]:

$$\mathbf{X}_L = \mathbf{H} \left(\mathbf{X}^\top \mathbf{G}_s^{-1} - \frac{\mathbf{X}^\top \mathbf{G}_s^{-1} \mathbf{1} \mathbf{G}_s^{-1}}{\mathbf{1} \mathbf{G}_s^{-1} \mathbf{1}} \right)^\top$$

\mathbf{G}_s es una matriz de conectividad espacial que ajusta las contribuciones de los canales vecinos, y \mathbf{H} es una matriz de ponderación.



Conecividad Funcional Gaussiana

Dada $\mathbf{X}_n \in \mathbb{R}^{C \times T}$, y el conjunto de etiquetas de MI $y_r \in \mathbb{R}[0, 1]$: para $n = 1, \dots, N$, se busca encontrar las relaciones entre canales que minicen:

$$v^* = \arg \min \mathbb{E} \left\{ \left\| \sum_{c < c'} \tilde{P}_{c, c'} \left(r; \mathbf{u}^{cc'}, kG(., \sigma) \right) - y_r \right\|_2^2 : \forall r, c, c' \right\} + \alpha_1 \|v\|_1 + \alpha_2 \|v\|_2$$

$\sum_{c < c'} \tilde{P}_{c, c'}$: conectividad funcional entre pares de canales EEG, $\mathbf{u}^{cc'}$: vector de pesos de relevancia entre canales c y c' , kG : kernel Gaussiano; α_1 y α_2 : términos de penalización

[García-Murillo et al., 2021].



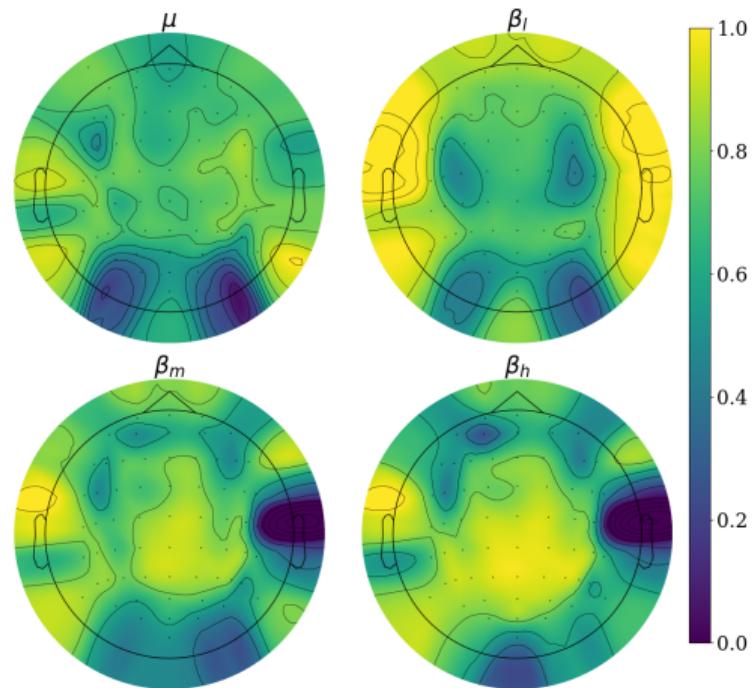
Flujo de Conectividades a Topogramas

La conectividades se transforman en un flujo de conectividades, donde:

$$X \in \mathbb{R}^{TxCx\Delta x\Omega}$$

Se utiliza una interpolación topográfica bidimensional a partir de la suma de contribuciones de conectividad a lo largo de todos los canales:

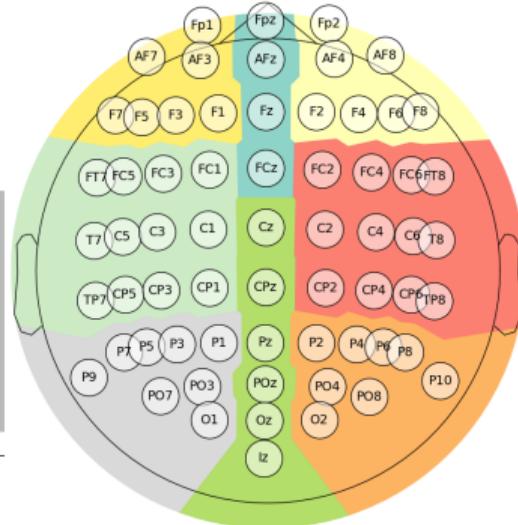
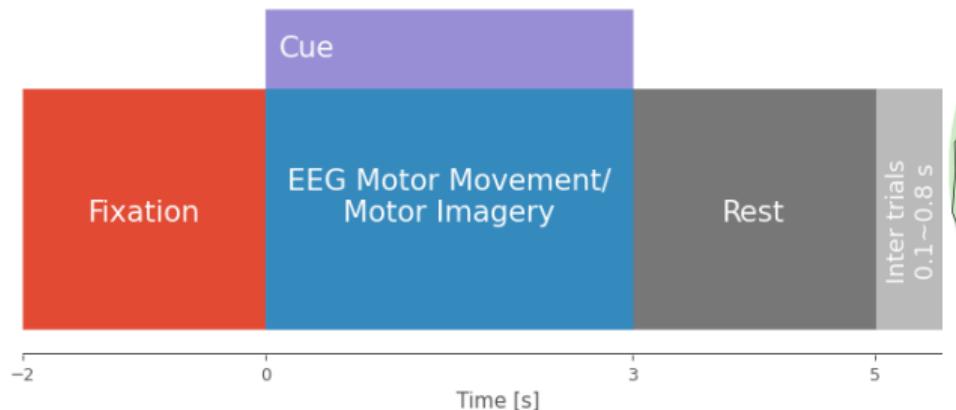
$$\mathbb{R}^c \rightarrow \mathbb{R}^{W \times H}$$





Base de datos Giga Motor Imagery - DBIII MI

Contiene los registros de EEG de cincuenta y dos (52) sujetos, 200 intentos, 64 canales con montaje 10-20.

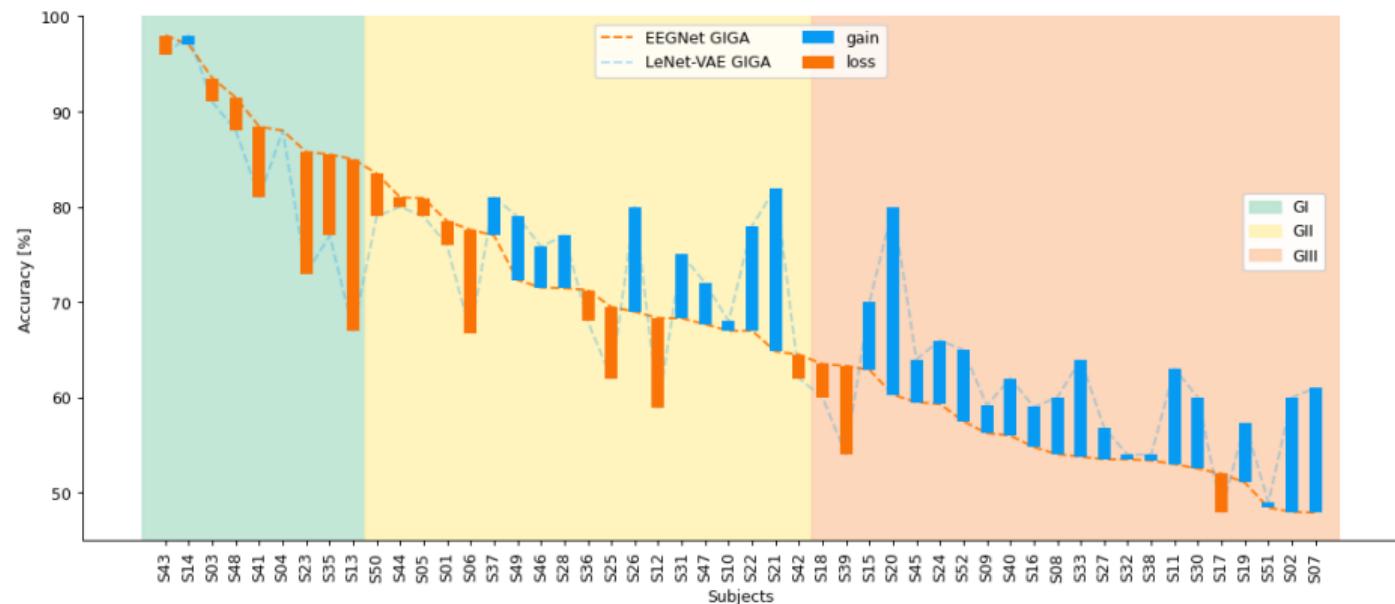


Preproceso: recorte de 2,5s de MI.



Resultados

Análisis por Grupos con EEGnet vs NRVAE en Giga Motor Imagery - DBIII MI División por grupos (G I: pérdida de 3.26 %, G II: ganancia de 1.16 % y el G III: ganancia de 4.25 %).





Análisis de Grupo para Giga Motor Imagery - DBIII MI

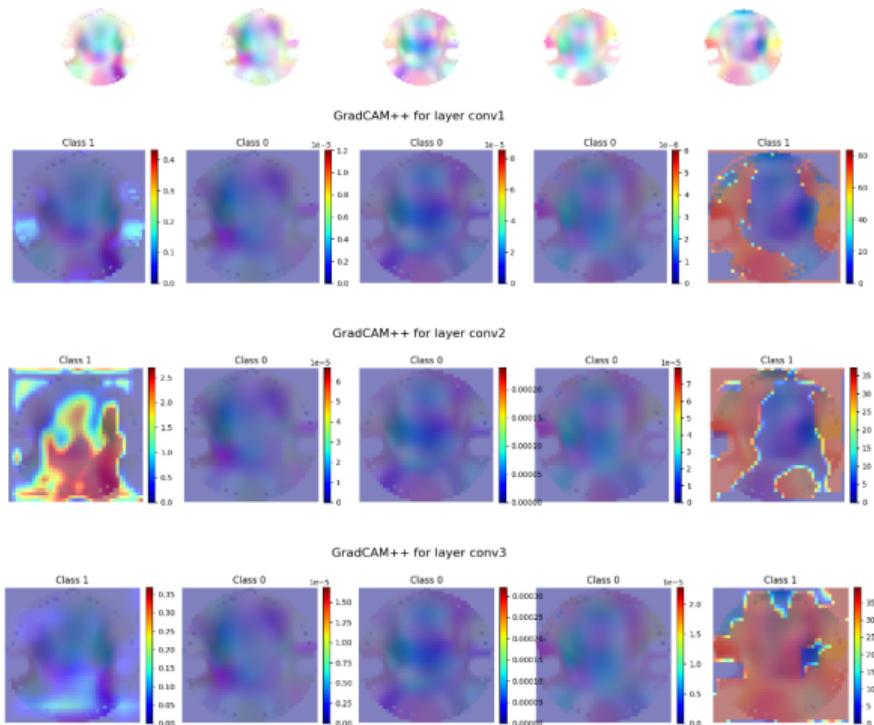
Análisis de rendimiento por grupos para EEGNet y NRVAE.

Método	Grupo	Acierto (%)	Ganancia (%)
EEGNet	GI	89.59	.
	GII	72.07	.
	GIII	55.58	.
NRVAE	GI	86.33	
	GII	73.23	1.16
	GIII	59.83	4.25



Resultados

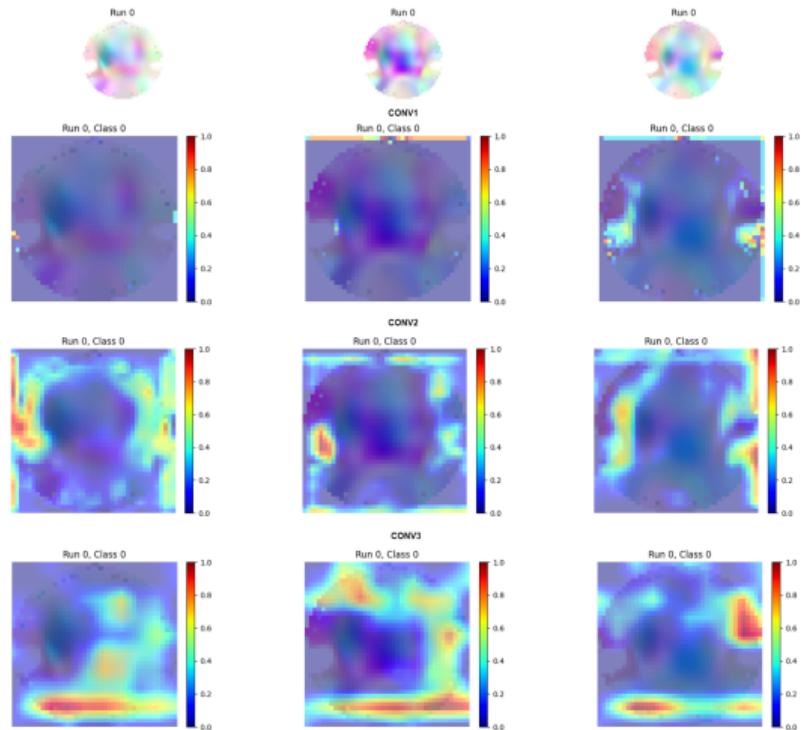
CAMS por clases.





Resultados

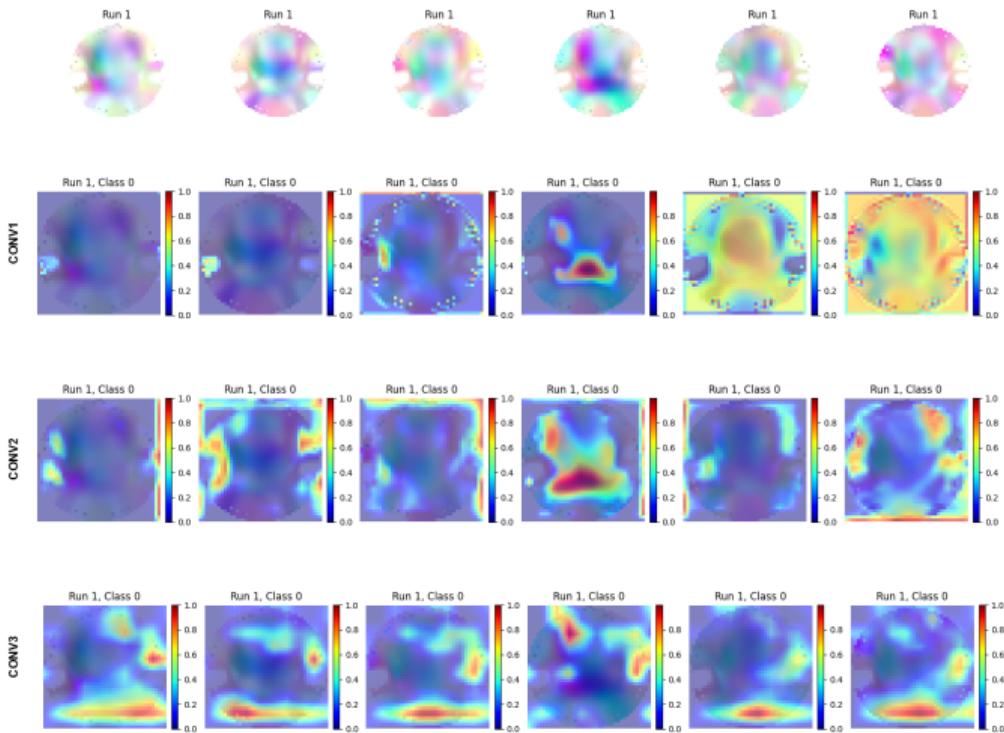
CAMS por runs, run 0





Resultados

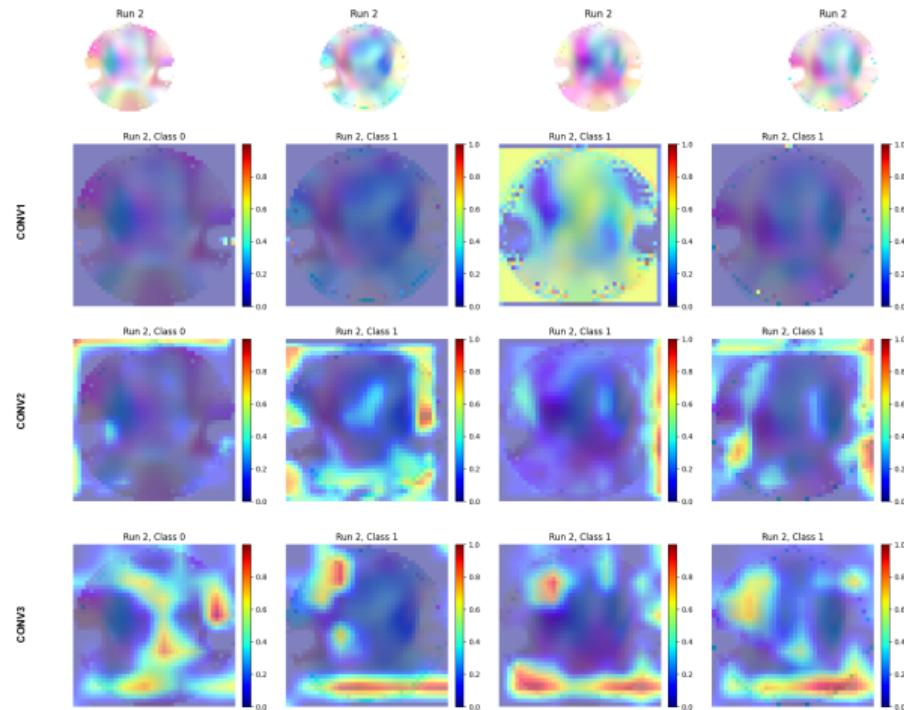
Run 1





Resultados

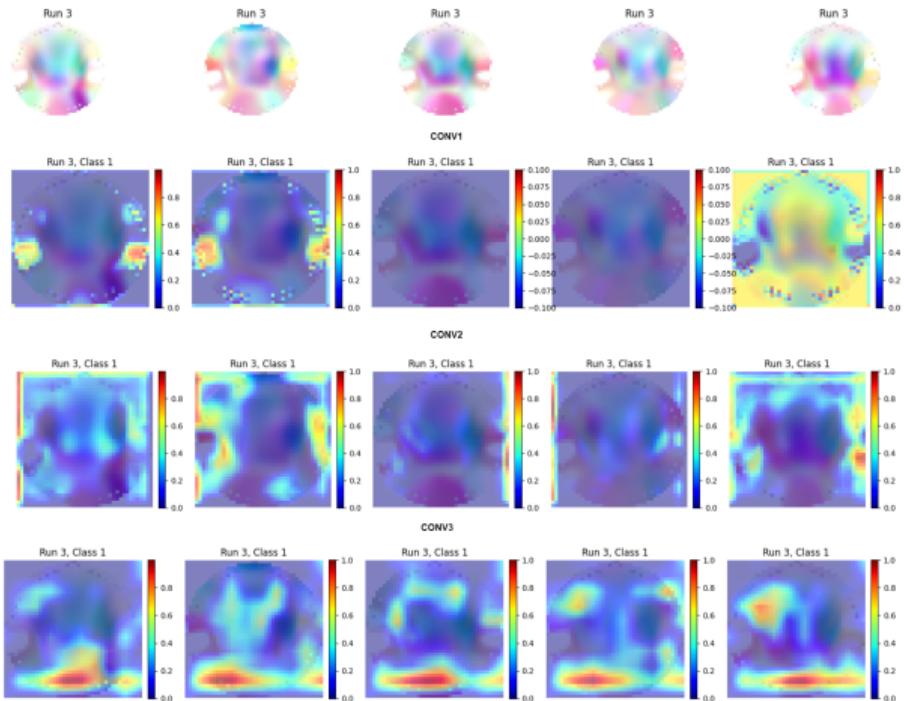
Run 2





Resultados

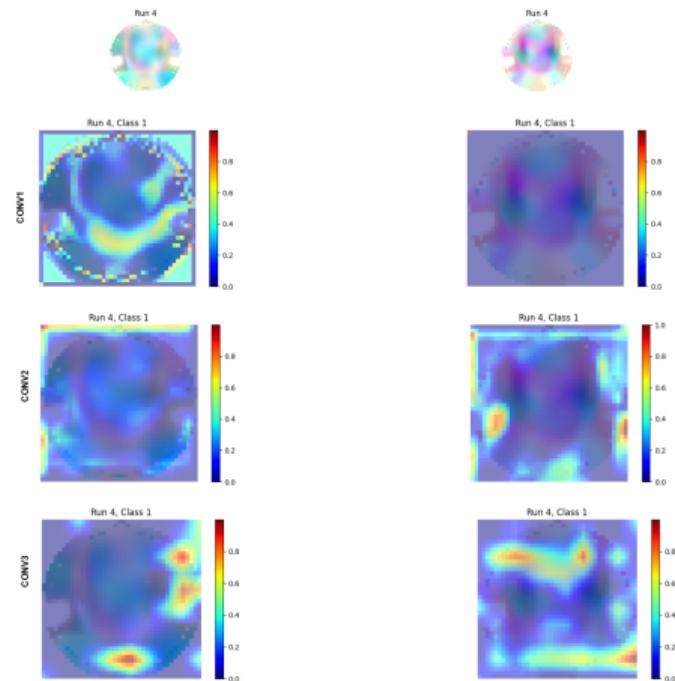
Run 3





Resultados

Run 4





Resultados

Función de pérdida para el sujeto 43

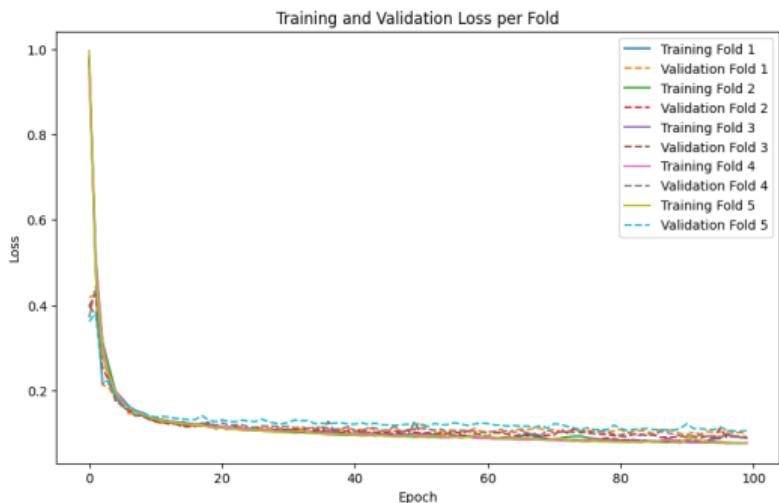


Figura: Pérdida Normalizada

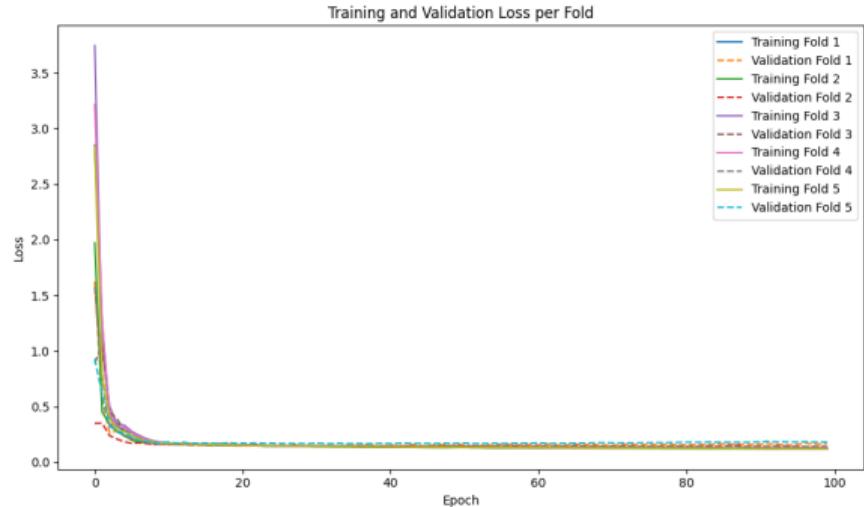


Figura: Pérdida sin Normalizar



Resultados

Función de pérdida para el sujeto 51

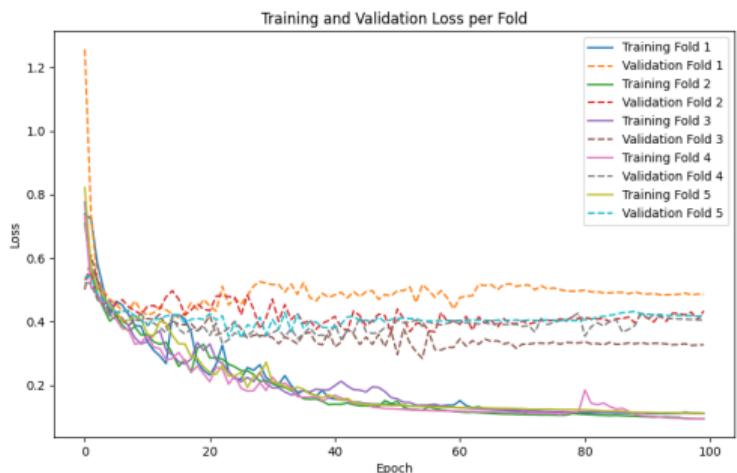


Figura: Pérdida Normalizada

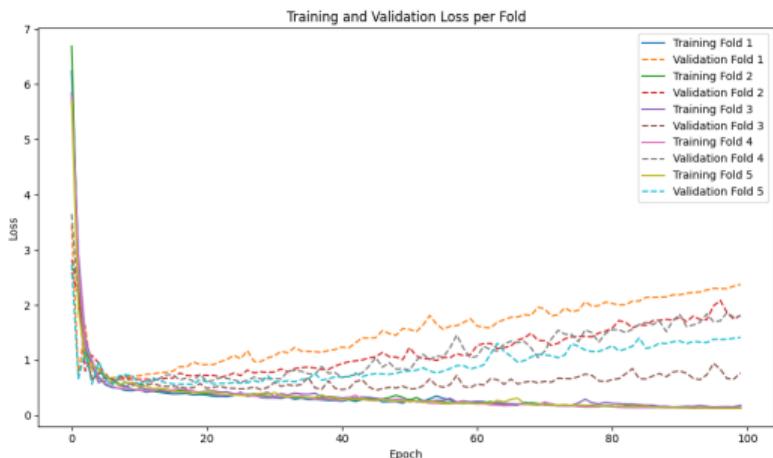
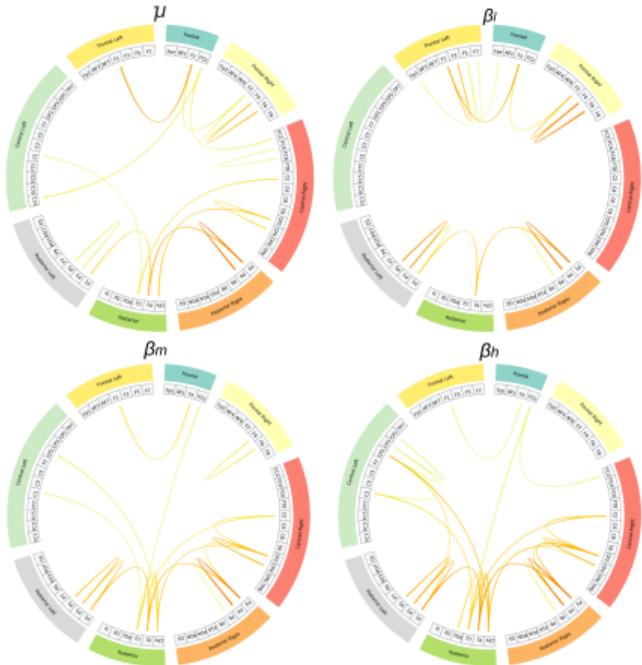


Figura: Pérdida sin Normalizar



Mapas de Conectividad de Giga Motor Imagery - DBIII MI

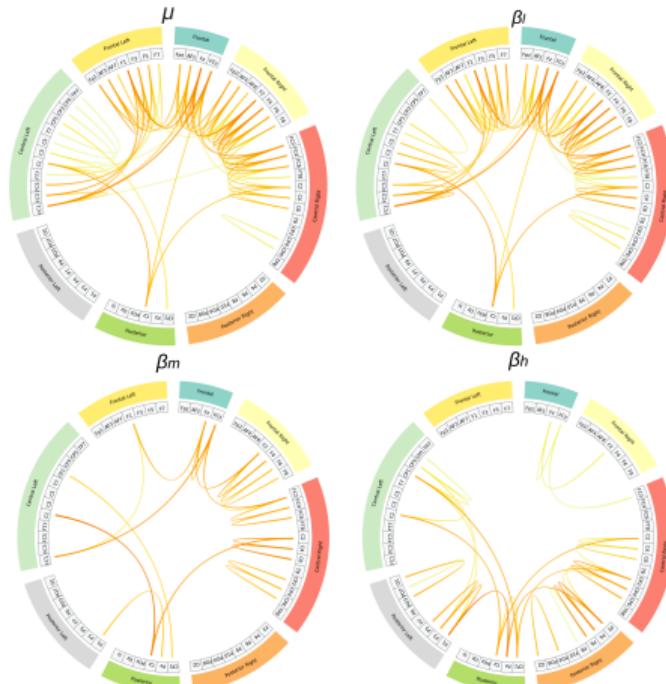
La GFC estimada en las cuatro bandas de frecuencia estudiadas, sujeto 43.





Mapas de Conectividad de Giga Motor Imagery - DBIII MI

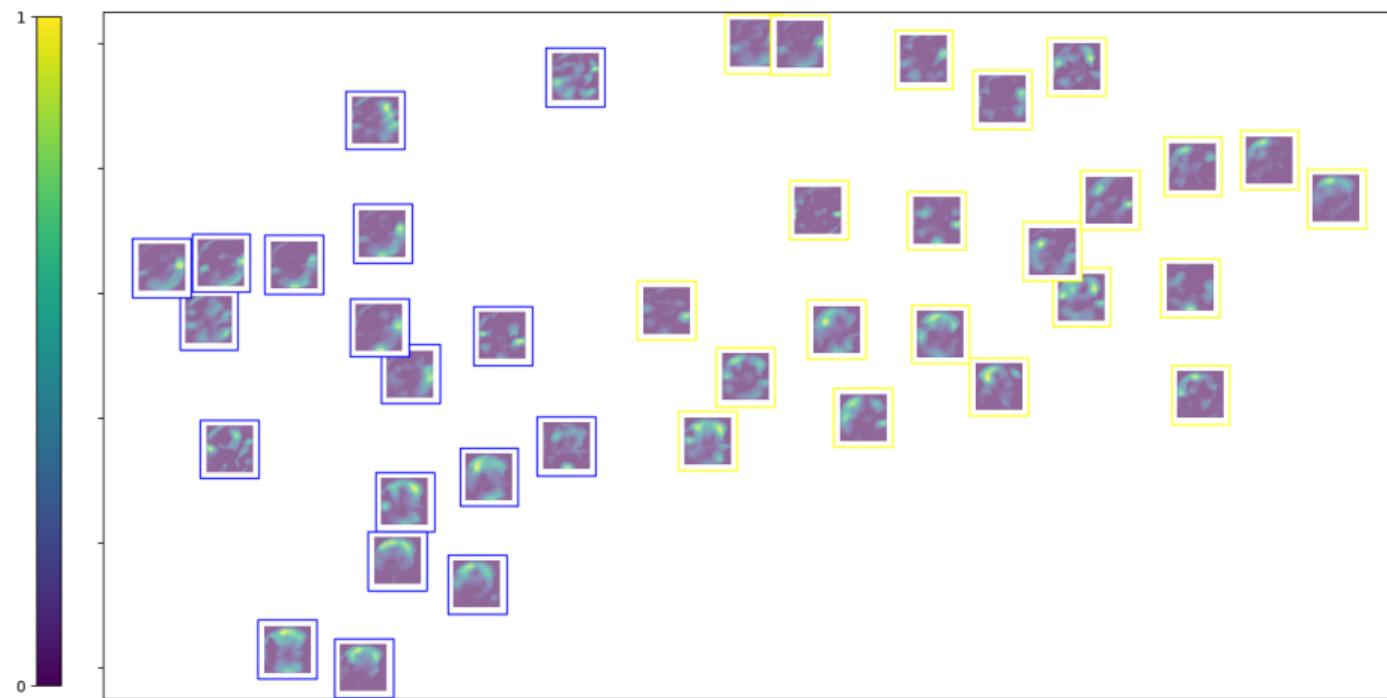
La GFC estimada en las cuatro bandas de frecuencia estudiadas, sujeto 51.





Análisis con t-SNE de Giga Motor Imagery - DBIII MI

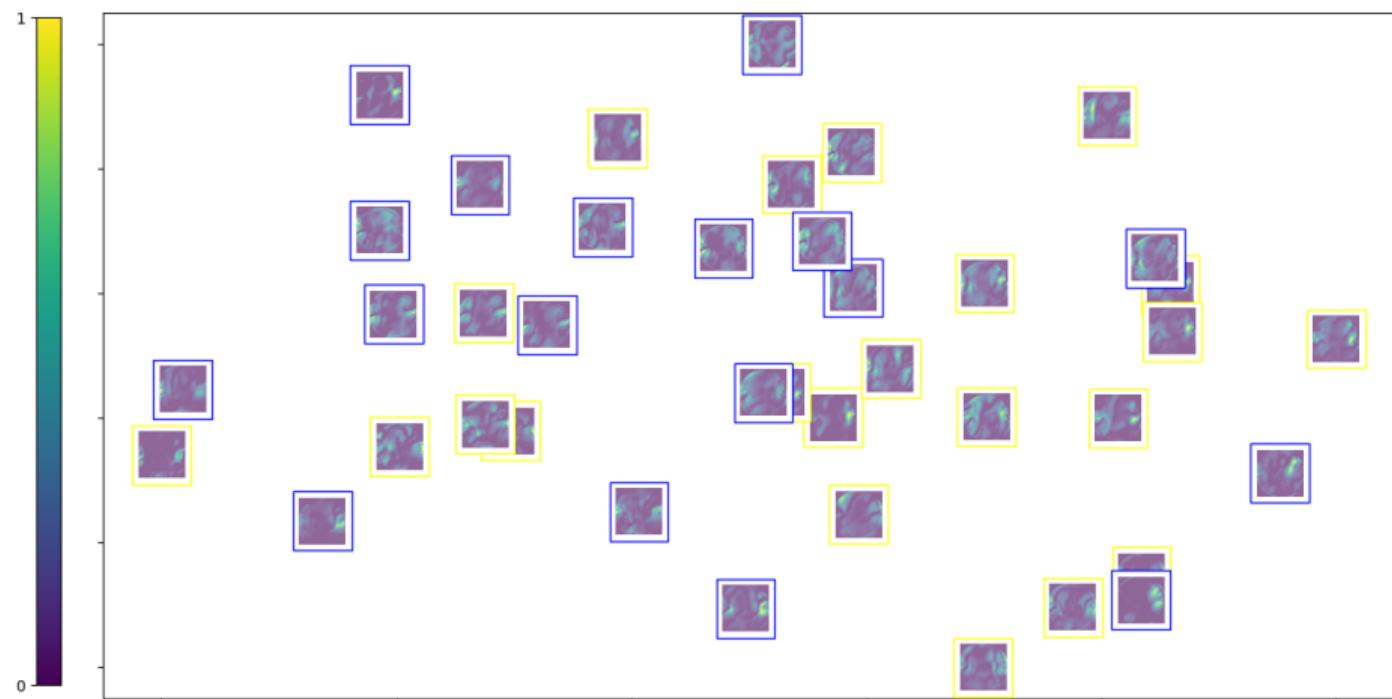
Proyección 2D de t-SNE de los Mapas de Activación de Clase (CAMs) para el sujeto 43.





Análisis con t-SNE de Giga Motor Imagery - DBIII MI

Proyección 2D de t-SNE de los CAMs para el sujeto 51.





Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

4 Metodología

5 Conclusiones

6 Referencias



Conclusiones

- En el grupo III, compuesto por sujetos de rendimiento bajo, se observó una ganancia significativa del 4.25 %, lo que sugiere que el NRVAE es particularmente efectivo para mejorar el rendimiento en este grupo de sujetos.
- En el grupo II, correspondiente a los sujetos de rendimiento regular, se obtuvo una mejora del 1.16 %, lo cual indica una ligera ganancia en el rendimiento al aplicar el modelo propuesto.
- Sin embargo, en el grupo I, que incluye a los sujetos de mejor rendimiento, se presentó una pérdida del 3.26 %, lo que indica que el modelo podría no ser tan beneficioso para sujetos con un rendimiento alto desde el inicio.



Conclusiones

- En el caso del t-SNE, se evidenció una excelente separabilidad entre clases para el sujeto con mejor rendimiento, lo que sugiere que los patrones de actividad cerebral en este individuo están claramente diferenciados y bien representados en el espacio proyectado.
- En el análisis de las conectividades cerebrales, las conexiones entre las diferentes zonas del cerebro no mostraron ser espurias, indicando que las relaciones funcionales identificadas reflejan conexiones genuinas.



Contenido

1 Motivación

2 Planteamiento del Problema

3 Estado del Arte

4 Metodología

5 Conclusiones

6 Referencias



Referencias I



Bozhokin, S. V. and Suslova, I. B. (2021).

Wavelet correlation of non-stationary bursts of eeg.
In *BIO SIGNALS*, pages 142–149.



Cardona-Álvarez, Y. N., Álvarez-Meza, A. M., Cárdenas-Peña, D. A., Castaño-Duque, G. A., and Castellanos-Dominguez, G. (2023).

A novel openbci framework for eeg-based neurophysiological experiments.
Sensors, 23(7):3763.



Carvalhaes, C. and De Barros, J. (2015).

The surface laplacian technique in EEG: Theory and methods.
International Journal of Psychophysiology, 97(3):174–188.



Chintamani, R. D. et al. (2021).

Analysis of motor imagery eeg classification based on feature extraction and machine learning algorithm.
INFORMATION TECHNOLOGY IN INDUSTRY, 9(2):541–553.



Choi, I., Kwon, G. H., Lee, S., and Nam, C. S. (2020).

Functional electrical stimulation controlled by motor imagery brain-computer interface for rehabilitation.
Brain Sciences, 10(8):512.



Farahani, F. V., Karwowski, W., and Lighthall, N. R. (2019).

Application of graph theory for identifying connectivity patterns in human brain networks: a systematic review.
frontiers in Neuroscience, 13:585.



Referencias II



Fraiwan, M., Alafeef, M., and Almomani, F. (2021).

Gauging human visual interest using multiscale entropy analysis of eeg signals.
Journal of Ambient Intelligence and Humanized Computing, 12(2):2435–2447.



García-Murillo, D. G., Alvarez-Meza, A., and Castellanos-Dominguez, G. (2021).

Single-trial kernel-based functional connectivity for enhanced feature extraction in motor-related tasks.
Sensors, 21(8):2750.



García-Murillo, D. G., Álvarez-Meza, A. M., and Castellanos-Dominguez, C. G. (2023).

Kcs-fcnet: Kernel cross-spectral functional connectivity network for eeg-based motor imagery classification.
Diagnostics, 13(6):1122.



Hsu, W.-Y. (2014).

Improving classification accuracy of motor imagery eeg using genetic feature selection.
Clinical EEG and neuroscience, 45(3):163–168.



Meng, C., Trinh, L., Xu, N., Enouen, J., and Liu, Y. (2022).

Interpretability and fairness evaluation of deep learning models on mimic-iv dataset.
Scientific Reports, 12(1):7166.



Miao, M., Hu, W., Yin, H., and Zhang, K. (2020).

Spatial-frequency feature learning and classification of motor imagery eeg based on deep convolution neural network.
Computational and mathematical methods in medicine, 2020.



Referencias III



Mir, W. A., Anjum, M., and Shahab, S. (2023).

Deep-eeg: an optimized and robust framework and method for eeg-based diagnosis of epileptic seizure.
Diagnostics, 13(4):773.



Padfield, N., Zabalza, J., Zhao, H., Masero, V., and Ren, J. (2019).

Eeg-based brain-computer interfaces using motor-imagery: Techniques and challenges.
Sensors, 19(6):1423.



Peksa, J. and Mamchur, D. (2023).

State-of-the-art on brain-computer interface technology.
Sensors, 23(13):6001.



Taherian, S. and Davies, T. C. (2018).

Caregiver and special education staff perspectives of a commercial brain-computer interface as access technology: a qualitative study.
Brain-Computer Interfaces, 5(2-3):73–87.



Tremmel, C., Herff, C., Sato, T., Rechowicz, K., Yamani, Y., and Krusienski, D. J. (2019).

Estimating cognitive workload in an interactive virtual reality environment using eeg.
Frontiers in human neuroscience, 13:401.



Wriessnegger, S. C., Müller-Putz, G. R., Brunner, C., and Sburlea, A. I. (2020).

Inter-and intra-individual variability in brain oscillations during sports motor imagery.
Frontiers in human neuroscience, 14:576241.



Referencias IV

 Xygonakis, I., Athanasiou, A., Pandria, N., Kugiumtzis, D., Bamidis, P. D., et al. (2018).

Decoding motor imagery through common spatial pattern filters at the eeg source space.

Computational intelligence and neuroscience, 2018.

 Zapparoli, L., Sacheli, L. M., Seghezzi, S., Preti, M., Stucovitz, E., Negrini, F., Pelosi, C., Ursino, N., Banfi, G., and Paulesu, E. (2020).

Motor imagery training speeds up gait recovery and decreases the risk of falls in patients submitted to total knee arthroplasty.

Scientific reports, 10(1):8917.